Stability-Penalized Split Selection for Decision Tree Classification: Sebuah Evaluasi Multi-Dataset yang Reproducible

Rofiq Fauzi (p36202600047@mhs.dinus.ac.id), Magister Artificial Intelligence, Universitas Dian Nuswantoro

Kata kunci–pohon keputusan; kriteria split; stabilitas bootstrap; variansi gain; *nested cross-validation*; perbandingan statistik nonparametrik.

Abstrak

Pohon keputusan CART dikenal cepat dan interpretabel, namun struktur pohonnya tidak stabil: perubahan kecil pada data latih dapat mengubah split yang terpilih dan akhirnya prediksi. Penelitian ini mengevaluasi sebuah formulasi kandidat yang sangat sederhana, dinamai *Stability-Penalized Decision Tree* (SPDT), di mana skor setiap kandidat split dihitung sebagai gain Gini dikurangi penalti berbobot terhadap variansi gain tersebut atas resample bootstrap dari data node: `Score(s) = Gain(s,D) − lambda*Var_b[Gain(s,D^(b))]`. Penelusuran literatur hingga 22 Oktober 2026 tidak menemukan ekuivalen formula-level dari kriteria tersebut, tetapi ruang riset stabilitas pohon sudah ramai; karena itu formulasi diposisikan sebagai kandidat, bukan klaim metode baru. Evaluasi dilakukan pada 8 dataset klasifikasi tabular UCI dengan *nested cross-validation* berulang (5 fold x 3 ulangan pada tiga seed), penyetelan hyperparameter di inner loop, dan Macro-F1 sebagai metrik primer. Hasil: SPDT vs CART custom (lambda=0) mencatat 6 menang, 0 seri, 2 kalah dengan rata-rata Delta Macro-F1 +0.0058. Uji Friedman menunjukkan chi^2(2)=4.0000, p=0.1353, Kendall W=0.2500 – tidak cukup bukti untuk menolak hipotesis nol, sehingga perbandingan post-hoc konfirmatori tidak dijalankan. Ablation menunjukkan besar lambda dan jumlah resample B nyaris tidak memengaruhi Macro-F1, pembatasan kedalaman lebih menentukan, dan ukuran stabilitas prediksi SPDT sedikit lebih buruk daripada CART custom dengan overhead waktu fit +/-40x. Temuan ini merupakan hasil nol yang jujur: pada delapan dataset kecil-menengah yang diuji, penalti variansi bootstrap atas gain split tidak memberikan manfaat yang cukup untuk menandingi kesederhanaan CART, tanpa menutup kemungkinan manfaat pada regime data lain.

I. Pendahuluan

Pohon keputusan adalah metode klasifikasi nonparametrik yang mempartisi ruang fitur secara rekursif. Kriteria split CART memilih kandidat (fitur, ambang) yang memaksimalkan penurunan impuritas Gini (Breiman et al. 1984; Quinlan 1986). Namun demikian, struktur pohon diketahui tidak stabil: perturbasi kecil pada data latih dapat mengubah split yang terpilih (Li and Clarke 2002), dan konsekuensinya prediksi berubah – fenomena inilah yang melatarbelakangi *bagging* dan *random forests* (Breiman 1996, 2001; Dietterich 2000).

Berbagai pendekatan telah mengurangi instabilitas tersebut pada tingkat yang berbeda: filter signifikansi statistik, pembatasan struktural, agregasi ensemble, atau pemilihan model yang stabil (Briand et al. 2009; Lee et al. 2024; Mirzamomen and Kangavari 2017; Wang et al. 2017). Yang jarang diuji secara langsung adalah pertanyaan yang lebih sempit ini:

> **Apakah penalti variansi bootstrap atas gain split, dikurangkan langsung dari skor split, dapat meningkatkan Macro-F1 out-of-sample dan/atau stabilitas prediksi dibandingkan CART standar pada resampling berulang, dengan biaya runtime yang dapat diterima?**

Hipotesis nol: tidak ada peningkatan sistematis dibandingkan baseline lintas dataset independen. Tidak ada hipotesis bahwa SPDT *harus* unggul.

Kontribusi yang diklaim terbatas pada: (i) formulasi kandidat yang eksplisit; (ii) implementasi dan audit reproducible; (iii) evaluasi nested-CV yang bebas *leakage*; (iv) ablation dan analisis statistik yang jujur terhadap hasil positif maupun negatif.

II. Karya Terkait

Stabilitas pohon keputusan. Instabilitas struktural pohon dibahas secara formal oleh Li dan Clarke (Li and Clarke 2002); pengukuran kuantitatif stabilitas dan kemiripan antar pohon dikembangkan antara lain oleh Turney (Turney 1995) serta Briand dkk. (Briand et al. 2009), yang juga mengevaluasi stabilisasi node berbasis bootstrap (lini NLS/Dannegger). Lee dkk. (Lee et al. 2024) mengusulkan ANLS yang menjalankan iterasi bootstrap pada setiap node dan memilih prediktor terpilih terbanyak – mekanisme resampling-node yang paling dekat dengan penelitian ini, tetapi agregasinya memakai voting frekuensi, bukan penalti variansi gain. Mirzamomen dan Kangavari (Mirzamomen and Kangavari 2017) menstabilkan melalui uji split multi-atribut.

Kriteria split alternatif. Kriteria berbasis entropi Tsallis dua-suku (Wang et al. 2017), kriteria *robust* terhadap label

noise (Yang et al. 2019), pemilihan split tak-bias berbasis statistik Gini (Strobl et al. 2007), dan pohon arus data dengan batas keyakinan Hoeffding (Domingos and Hulten 2000) menunjukkan bahwa ruang "mengubah skor split" sudah aktif diteliti. Delise (Delise 2026) menilai konsistensi gain lintas *environment* pada boosting. Penalti skor oleh variansi estimasi resampled juga dikenal di luar pohon (pola mean-variance pada seleksi model). Tidak satu pun dari karya yang berhasil diverifikasi memuat rumus `Gain - lambda*Var_bootstrap[Gain];` namun demikian temuan negatif penelusuran bukan bukti kebaruan, sehingga formulasi tetap dicap sebagai kandidat.

III. Metode

A. Kriteria split yang diusulkan: Untuk node dengan data D (hanya bagian latih yang sah), dengan `Gini(D) = 1 - Sum_c p(c|D)^2` dan gain split

```
Gain(s,D) = Gini(D) -
(|D_L|/|D|)*Gini(D_L) -
(|D_R|/|D|)*Gini(D_R),
```

dibangun B resample bootstrap `D^(b)` dari baris node. Untuk setiap kandidat s yang valid:

`V(s) = Var_b[Gain(s,D^(b))]` (varians sampel, ddof=1)

Skor utama: `Score(s) = Gain(s,D) - lambda*V(s)`.

Kebijakan deterministik: ambang kandidat = titik tengah nilai unik terurut; `min_samples_leaf`/`min_samples_split` pada jumlah asli node; partisi child kosong dalam resample berkontribusi 0; daun memilih kelas mayoritas dengan tie-break label terkecil; seed bootstrap diturunkan dari `(random_state, id node)`. Untuk lambda=0 seluruh komputasi bootstrap dilewati dan estimator terdegenerasi menjadi CART custom referensi (diverifikasi identik dengan implementasi referensi independen pada pengujian unit). Sebuah varian eksploratori terpisah (normalisasi `V/(Gain^2+eps)`) dicatat tetapi bukan metode utama. Keterbatasan penting: V(s) *scale-dependent* terhadap gain.

B. Desain evaluasi: Dataset: 8 dataset klasifikasi tabular UCI (Tabel I). Protokol: *repeated stratified nested CV* – outer 5 fold x 3 ulangan untuk masing-masing seed [42, 123, 2026] (45 evaluasi per dataset-metode, split identik untuk semua metode); inner 3-fold stratified untuk penyetelan dengan seed deterministik. Preprocessing hanya imputasi median yang di-fit pada bagian latih (pipeline). Metrik primer Macro-F1; sekunder: balanced accuracy, accuracy, waktu fit/prediksi, jumlah node, kedalaman. Stabilitas prediksi diukur terpisah sebagai *disagreement* rata-rata pairwise antar model yang dilatih pada 10 sub-sampel 90% dari data latih outer, dievaluasi pada outer test yang sama – dilaporkan terpisah dari akurasi.

TABLE I: Inventaris dataset.

Dataset	N	Fitur	Kelas	Sumber
banknote	1372	4	2	ucimlrepo
glass	214	9	6	ucimlrepo
ionosphere	351	34	2	ucimlrepo
iris	150	4	3	ucimlrepo
seeds	210	7	3	uci_static_zip
sonar	208	60	2	ucimlrepo
wdbc	569	30	2	ucimlrepo
wine	178	13	3	ucimlrepo

C. Analisis statistik: Unit inferensi adalah dataset (rata-rata 45 outer fold), bukan fold. Perbandingan tiga metode primer (CART sklearn, CART custom lambda=0, SPDT) menggunakan uji Friedman dengan dataset sebagai blok; bila omnibus memberikan alasan, dilanjutkan Wilcoxon signed-rank berpasangan dengan koreksi Holm dan effect size rank-biserial. p >= 0.05 tidak pernah diartikan sebagai bukti kesetaraan. Random forest disertakan sebagai benchmark kontekstual non-ekuivalen dan tidak masuk uji omnibus primer.

IV. Hasil dan Pembahasan

Post-hoc tidak dijalankan: uji omnibus Friedman tidak memberikan alasan (p >= 0.05), sesuai protokol.

Table: Perbandingan berpasangan (post-hoc).

Ringkasan berpasangan SPDT vs CART custom: **6 menang / 0 seri / 2 kalah**, rata-rata Delta Macro-F1 +0.0058.

Pembahasan. Hasil bersifat deskriptif condong mendukung SPDT tetapi tidak mencapai bukti konfirmatori. SPDT mencatat mean rank terbaik (1.500 vs 2.000 CART sklearn dan 2.500 CART custom) dan menang pada 6 dari 8 dataset berpasangan terhadap CART custom, namun uji Friedman tidak menemukan bukti perbedaan yang cukup (p = 0.1353) dan perbandingan eksploratif SPDT-CART custom menghasilkan p mentah 0.078 – tidak bertahan pada taraf 5% dan tidak boleh ditafsirkan sebagai signifikan. Dengan hanya 8 dataset, power statistik terbatas; sesuai protokol, hasil ini dilaporkan apa adanya dan p >= 0.05 tidak diartikan sebagai kesetaraan.

Temuan penting kedua: penalti stabilitas tidak menurunkan *prediction disagreement* – SPDT justru sedikit lebih tinggi (0.101) dibanding CART custom (0.093) dan CART sklearn (0.101). Random forest tetap paling stabil (0.027) melalui agregasi ensemble. Dengan demikian, janji motivasi metode (stabilitas prediksi lebih baik) **tidak terwujud** pada benchmark ini; penalti variansi gain bukan pengganti ensemble.

Temuan ketiga dari ablation pada split identik: besar penalti lambda maupun jumlah resample B nyaris tidak mengubah Macro-F1 (semua varian lambda dan B di kisaran 0.859-0.861), sedangkan pembatasan kedalaman/ukuran daun jauh lebih menentukan (depth 3 turun ke +/-0.836). Penyetelan inner cenderung memilih lambda besar (10 pada 64.7% fold)

TABLE II: Macro-F1 mean +/- sd (deskriptif, fold-level) per dataset dan metode.

Dataset	CART-skl	CART-cust	SPDT	RF	SPDT-CART
banknote	0.982 +/- 0.008	0.981 +/- 0.007	0.981 +/- 0.007	0.994 +/- 0.004	+0.0004
glass	0.620 +/- 0.097	0.609 +/- 0.093	0.626 +/- 0.093	0.742 +/- 0.075	+0.0166
ionosphere	0.873 +/- 0.034	0.881 +/- 0.038	0.879 +/- 0.038	0.929 +/- 0.037	-0.0027
iris	0.949 +/- 0.033	0.945 +/- 0.038	0.944 +/- 0.037	0.955 +/- 0.034	-0.0008
seeds	0.897 +/- 0.032	0.906 +/- 0.036	0.913 +/- 0.034	0.923 +/- 0.038	+0.0066
sonar	0.719 +/- 0.065	0.706 +/- 0.073	0.725 +/- 0.061	0.833 +/- 0.065	+0.0189
wdbc	0.925 +/- 0.031	0.925 +/- 0.030	0.928 +/- 0.030	0.956 +/- 0.023	+0.0037
wine	0.905 +/- 0.047	0.905 +/- 0.044	0.909 +/- 0.046	0.981 +/- 0.024	+0.0040

TABLE III: Mean rank Macro-F1.

Metode	Mean rank
SPDT	1.500
CART-skl	2.000
CART-cust	2.500

dan B kecil (5 pada 53.1%), yang mengindikasikan penalti sering dipilih tetapi efeknya pada akurasi kecil. Biayanya nyata: waktu fit SPDT +/-40x CART custom. Secara keseluruhan, efektivitas penalti variansi bootstrap bergantung dataset dan kecil magnitude-nya; simple distance/impurity splitting tetap preferable untuk dataset kecil-menengah ini.

V. Kesimpulan

Penelitian ini mengevaluasi formulasi kandidat SPDT secara reproducible dengan nested repeated CV bebas leakage, ablation terkontrol pada split identik, dan analisis statistik level-dataset pada 8 dataset UCI. Secara deskriptif SPDT memperoleh mean rank terbaik dan menang berpasangan pada 6 dari 8 dataset terhadap CART custom, tetapi uji Friedman tidak memberikan bukti perbedaan yang cukup (chiˆ2(2)=4.0000, p=0.1353), sehingga tidak ada dasar konfirmatori untuk mengklaim peningkatan. Lebih lanjut, ukuran stabilitas prediksi tidak membaik dan justru sedikit memburuk, sementara biaya komputasi naik +/-40x. Pada kondisi yang diuji, kesederhanaan CART tetap preferable. Keterbatasan: delapan dataset kecil, impuritas Gini saja, proxy stabilitas berbasis disagreement, klaim kebaruan formula-level yang belum established, dan belum dibandingkannya kriteria terdekat dari literatur (ANLS, minimax split). Pekerjaan lanjutan yang paling bernilai: membandingkan langsung dengan stabilisasi bootstrap-node dari literatur, mengkaji normalisasi penalti oleh skala gain, dan menguji pada benchmark yang lebih besar.

Referensi

Breiman, Leo. 1996. "Bagging Predictors." *Machine Learning* 24 (2): 123–40. https://doi.org/10.1023/A:1018054314350.

Breiman, Leo. 2001. "Random Forests." *Machine Learning* 45 (1): 5–32. https://doi.org/10.1023/A:1010933404324.

Breiman, Leo, Jerome H. Friedman, Richard A. Olshen, and Charles J. Stone. 1984. *Classification and Regression Trees*. Wadsworth; expanded edition Chapman & Hall/CRC, 1993.

Briand, Bénédicte, Gilles R. Ducharme, Vanessa Parache, and Catherine Mercat-Rommens. 2009. "A Similarity Measure to Assess the Stability of Classification Trees." *Computational Statistics & Data Analysis* 53 (4): 1208–17. https://doi.org/10.1016/j.csda.2008.10.033.

Delise, Timothy. 2026. "Era Splitting – Invariant Learning for Decision Trees." *Expert Systems with Applications* 299: 129687. https://doi.org/10.1016/j.eswa.2025.129687.

Dietterich, Thomas G. 2000. "An Experimental Comparison of Three Methods for Constructing Ensembles of Decision Trees: Bagging, Boosting, and Randomization." *Machine Learning* 40 (2): 139–57. https://doi.org/10.1023/A:1007607513941.

Domingos, Pedro, and Geoff Hulten. 2000. "Mining High-Speed Data Streams." *Proceedings of the Sixth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '00)*, 71–80. https://doi.org/10.1145/347090.347107.

Lee, Joon, Min Kyu Sim, and Jin-Seon Hong. 2024. "Assessing Decision Tree Stability: A Comprehensive Method for Generating a Stable Decision Tree." *IEEE Access* 12: 90061–72. https://doi.org/10.1109/ACCESS.2024.3419228.

Li, Rong-Hua, and Stewart Clarke. 2002. "Instability of Decision Tree Classification Algorithms." *Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '02)*, 570–75. https://doi.org/10.1145/775047.775131.

Mirzamomen, Zahra, and Mohammad Reza Kangavari. 2017. "A Framework to Induce More Stable Decision Trees for Pattern Classification." *Pattern Analysis and Applications* 20 (4): 991–1004. https://doi.org/10.1007/s10044-016-0542-2.

Quinlan, J. Ross. 1986. "Induction of Decision Trees." *Machine Learning* 1 (1): 81–106. https://doi.org/10.1023/A:

TABLE IV: Uji statistik dataset-level.

Uji	Statistik	db	p	#dataset	Kendall W	Keputusan
friedman	4.0000	2	0.1353	8	0.2500	tidak ada bukti omnibus; post-hoc tidak dijalankan

TABLE V: Biaya komputasi.

Metode	Fit (s)	Fit median (s)	Prediksi (s)	Node	Kedalaman
CART-cust	0.5340	0.4163	0.0009	26.6722	5.1000
CART-skl	0.2693	0.2605	0.0010	27.4222	5.2917
RF	1.1169	1.0863	0.0573	-	-
SPDT	21.4302	14.6491	0.0010	28.5944	5.4611

TABLE VI: Stabilitas prediksi (disagreement; bukan metrik akurasi).

Metode	Disagreement rata-rata	SD
CART-cust	0.0928	0.0853
CART-skl	0.0983	0.0885
RF	0.0271	0.0337
SPDT	0.1014	0.0934

TABLE VII: Ablation pada split identik.

Varian	F1 makro	SD	Fit (s)	Node
A0 (lam=0)	0.8599	0.1270	0.0201	37.6611
A1 (lam=.1)	0.8598	0.1256	0.0860	37.6111
A1 (lam=1)	0.8601	0.1255	0.0862	37.5278
A2 (B=20)	0.8601	0.1251	0.1136	37.4556
A2 (B=5)	0.8613	0.1243	0.0711	37.4667
A3 d3 l1	0.8357	0.1592	0.0371	12.8722
A3 d3 l5	0.8353	0.1546	0.0373	11.8611
A3 d8 l1	0.8592	0.1272	0.0821	35.2500
A3 d8 l5	0.8521	0.1381	0.0820	24.7389

TABLE VIII: Frekuensi seleksi hyperparameter SPDT (45 outer fold per dataset).

parameter	value	frequency	share
max_depth	5.0000	140	0.3889
max_depth	8.0000	102	0.2833
min_samples_leaf	1.0000	201	0.5583
min_samples_leaf	2.0000	97	0.2694
min_samples_split	2.0000	252	0.7000
min_samples_split	5.0000	69	0.1917
n_bootstrap	5.0000	191	0.5306
n_bootstrap	20.0000	87	0.2417
penalty_lambda	10.0000	233	0.6472
penalty_lambda	0.0000	61	0.1694

1022643204877.

Strobl, Carolin, Anne-Laure Boulesteix, and Thomas Augustin. 2007. “Unbiased Split Selection for Classification Trees Based on the Gini Index.” *Computational Statistics & Data Analysis* 52 (1): 483–501. https://doi.org/10.1016/j.csda.2006.12.030.

Turney, Peter D. 1995. “Bias and the Quantification of Stability.” *Machine Learning* 20 (1): 23–33. https://doi.org/10.1007/BF00993473.

Wang, Yisen, Shu-Tao Xia, and Jia Wu. 2017. “A Less-Greedy Two-Term Tsallis Entropy Information Metric Approach for Decision Tree Classification.” *Knowledge-Based Systems* 120: 34–42. https://doi.org/10.1016/j.knosys.2016.12.021.

Yang, Bo-Bo, Wei Gao, and Min Li. 2019. “On the Robust Splitting Criterion of Random Forest.” *2019 IEEE 19th International Conference on Data Mining (ICDM)*, 1420–25. https://doi.org/10.1109/ICDM.2019.00184.